

حسابرسی شواهد مدل‌های *in silico* در مهندسی پزشکی با نردبان اعتبار کودون‌تریس جنسیس

Auditing Evidence for In-Silico Models in Biomedical Engineering with the CodonTrace Genesis Credibility Ladder

پرواز جمیعی^۱

^۱پژوهشگر مستقل، مشهد، ایران، parvaz.jamie@gmail.com

ORCID: <https://orcid.org/0009-0002-9980-270X>

چکیده - برای مدل محاسباتی در مهندسی پزشکی، عدد دقت به‌تنهایی کافی نیست و باید روشن باشد شواهد حاضر چه ادعایی را نگه می‌دارند. این مقاله بستر کودون‌تریس جنسیس را معرفی می‌کند: اجرا قطعی است، مداخله روی یال سازوکار ثبت می‌شود، و ادعا روی نردبانی شش‌سطحی حسابرسی می‌شود. خود موتور حوزه را نمی‌شناسد. برچسب حوزه از پورت *DomainProfile* می‌آید و پروفایل زیست‌پزشکی همان نردبان را با واژگان *ASME V&V 40*، راهنمای *FDA* در سال ۲۰۲۳، *IEC 62304* و *IMDRF* هماهنگ می‌کند. در کمپین *HE01* با سی بذر جفتی، اختلاف انرژی نسبت به کنترل کانال روشن ۱۶۴۹ واحد و بازه *BCa* برابر [۱۴، ۱۹۱۴] بود. اجرای همان حسابرس روی جدول اعلامی یک مدل تجهیز، با ریسک مدل ۳ و برچسب‌های *IEC* و *FDA* در سطح صفر ماند.

کلید واژه- اعتبارسنجی *in silico*، حسابرسی شواهد، مدل‌سازی محاسباتی، نردبان اعتبار

۱- مقدمه

در پرونده مدل محاسباتی برای تجهیز پزشکی، سؤال اصلی این نیست که مدل چند درصد درست گفته است. سؤال این است که با شواهد موجود تا کجا می‌شود ادعا کرد. راهنمای نوامبر ۲۰۲۳ سازمان غذا و داروی آمریکا اعتبار مدل‌سازی و شبیه‌سازی فیزیک‌محور را به ریسک تصمیم وصل می‌کند و مدل یادگیری ماشین مستقل را بیرون از دامنه می‌گذارد [۱]. استاندارد *ASME V&V 40* همین نکته را با پرسش مورد علاقه، زمینه کاربرد و پیامد تصمیم می‌نویسد [۲]. *NASA-STD-7009B* جدا می‌خواهد که هم خود مدل قابل اتکا باشد و هم انتقال نتیجه به شرایط تازه مجاز باشد [۳]. پیوست چهارم قانون هوش مصنوعی اتحادیه اروپا نیز برای سامانه‌های مشمول، مستندسازی اعتبارسنجی را لازم کرده است [۴]. این سندها زبان مشترکی دارند، اما هیچ‌کدام به‌تنهایی درجه ادعای بسته‌شده به یک فایل پژوهشی را معلوم نمی‌کنند.

Viceconti و همکاران آزمون *in silico* را بر زمینه کاربرد، تحلیل ریسک، و زنجیره راستی‌آزمایی، اعتبارسنجی و کمی‌سازی عدم قطعیت گذاشته‌اند [۵]. *Pathmanathan* و همکاران همان زنجیره را تا اعتبار زیرمدل‌ها در آزمون بالینی درسلیکو برده‌اند [۱۷]. گزارش سمپوزیوم *FDA/MDIC* در سال ۲۰۲۴ هم اعتبار مدل را در طول عمر تجهیز، از جمله دوقلوی دیجیتال، جمع کرده است [۱۸]. آنچه کم است ابزاری است که بعد از انتشار هم بگوید این مصنوع کدام سطح ادعا را پشتیبانی می‌کند. در بررسی ۸۵ مقاله متکی به مدل زبانی در *ICSE* و *ASE* سال ۲۰۲۴، از پنج مصنوع اجرایی هیچ‌کدام کامل بازتولید نشد [۶]. تکرار اجرا هم به‌خودی‌خود سقف ادعا را نگه نمی‌دارد. این مقاله برای همان کار نوشته شده است.

در این بستر، اجرای قطعی، مداخله یال‌به‌یال و حسابرسی ادعا

کنار هم آمده‌اند و موتور برای پزشکی از نو نوشته نشده است. پروفایل زیست‌پزشکی واژگان تنظیم‌گری را روی همان نردبان می‌گذارد و برچسب را به‌جای تأیید نمی‌نشانند. خروجی ارزیابی هم دو تاست: کمپین *HE01* با شواهد جفتی بالا می‌رود و جدول اعلامی مدل تجهیز، با ریسک مدل ۳، در سطح صفر می‌ماند.

۲- پیشینه و کارهای مرتبط

درجه‌بندی اعتبار سابقه طولانی دارد، ولی اغلب در حد راهنما و گزارش نمونه مانده است. *ASME V&V 40.1-2026* یک نمونه کامل از همین چارچوب است و بدترین اندازه سینی تیپال را برای آزمون خستگی *ISO 14879-1* مشخص می‌کند [۷]. *IEC 62304* ردیف ایمنی نرم‌افزار پزشکی را A، B یا C می‌گذارد و حجم کار چرخه حیات را به همان رده وصل می‌کند [۸]. اسناد *IMDRF* زبان *SiMD* و *SamD* و نیز مشخصه‌سازی ریسک نرم‌افزار دستگاه را تثبیت کرده‌اند [۹]. [۱۰]. در این مقاله همان واژه‌ها به نردبانی وصل شده‌اند که روی بسته شواهد اجرا می‌شود.

آویدا بستر شناخته‌شده‌ای برای برنامه‌های خودتکثیرشونده است [۱۱] و پرونده *dat* آن از همین در خوانده می‌شود. در ادبیات کیفیت‌تنوع، پایداری عملکرد در محیط نامطمئن [۱۲] با بازپخش بیت‌به‌بیت یک اجرای نرم‌افزار یکی نیست. توصیف مدل بر اساس پروتکل *ODD* نوشته شده است [۱۳]. در پیکربندی هم یک خط قرمز هست: رشته *asme_vv40_passed* پذیرفته نمی‌شود.

۳- معماری سامانه

۳-۱- موتور و جداسازی پورت

هسته از ژنوم، عامل، جهان و زمان‌بند ساخته شده است. هر تنظیم تازه با پیش‌فرض خاموش وارد می‌شود تا آزمایش‌های قبلی

به هم نریزد. مسیر از ژنوم به کنش، پیامد، کپسول دارای منشأ، پذیرش و در نهایت بقا می‌رسد. برای هر یال، شناسه و اثرانگشت قبل و بعد ذخیره می‌شود تا عبور یک پیام با عوض شدن رفتار اشتباه گرفته نشود. شماره نسخه از پرونده پیکربندی پروژه خوانده می‌شود و داخل بسته شواهد ثابت نوشته نمی‌شود.

موتور نمی‌داند آزمایش مربوط به پزشکی است یا زندگی مصنوعی یا سخت‌افزار. این برجسب از بیرون می‌آید. آداپتور بسته شواهد را می‌سازد و DomainProfile فقط نام حوزه را با خود دارد. حوزه تازه یعنی پروفایل تازه، نه موتور دوم. شکل ۱ همین جدایی را نشان می‌دهد. موتور تیک، اثرانگشت و بازپخش را انجام می‌دهد و حسابرس فقط بسته را می‌بیند [۱۴].

0 Software capability source: API, tests

شکل ۱: معماری پورت‌ها. موتور حوزه نمی‌شناسد؛ حسابرس روی بسته شواهد کار می‌کند.

جدول ۱: پورت‌ها؛ حوزه در آداپتور است نه در موتور

پورت	ماژول	نقش موتور
کمپین بومی HE01	adapters.codontrace	خواندن مصنوع
کمپین / HE02 HE03	adapters.codontrace _he02/03	خواندن مصنوع
Avida (.dat)	adapters.avid	اسکلت
MABE2 (CSV)	adapters.mabe2	اسکلت
جدول امتیاز اعلامی	claimgate.domain	بدون موتور
برجسب زیست‌پزشکی	adapters.biomedical	بدون موتور
پل ESP32	adapters.esp32_brid ge	نمونه اختیاری

حسابرسی پنج مرحله دارد. آداپتور پرونده یا جدول را به یک بسته واحد برمی‌گرداند. نقش بازوها به پنج نقش کلی نگاشت می‌شود: درمان، حذف سازوکار، خاموش کردن کانال، کنترل منفی، و دوز. اثرانگشت پیکربندی و، اگر موجود باشد، اثرانگشت پیش‌ثبت‌نامه بررسی می‌شود. سپس بازپخش، مقایسه جفتی، بازه اطمینان و تعداد بدر خوانده می‌شود. بالاترین سطحی برمی‌گردد که همه شرط‌هایش برقرار باشد.

۳-۲- حسابرس و نردبان شواهد

حسابرس از موتور جداست و شش سطح دارد. سطح ۳ به مداخله یا حذف یال، کنترل منفی و بازپخش نیاز دارد. سطح ۴ بازه اطمینان و حداقل شانزده بذر را هم می‌خواهد. سطح ۵ علاوه بر اینها آرشو، محدودیت نوشته‌شده، و شواهد آماری و مداخله‌ای را با هم لازم دارد. این آستانه‌ها مربوط به همین پیاده‌سازی است. برابر بودن خروجی دو بازو، به‌خودی‌خود، نتیجه را باطل نمی‌کند. آزمون وقتی بی‌اعتبار شمرده می‌شود که خود مداخله هم اعمال نشده

باشد.

۳-۳- آداپتورها

آداپتور HE01 فایل JSON را می‌خواند و نقش محلی را به نقش کلی برمی‌گرداند. بایت خود پرونده عوض نمی‌شود. پرونده Avida و خروجی CSV مربوط به MABE2 هم از همین مسیر وارد می‌شوند. آداپتور زیست‌پزشکی جدول امتیاز را با زمینه کاربرد و ریسک مدل پر می‌کند. اتصال سخت‌افزاری **اختیاری** است. برای فایل متنی، اثرانگشت بعد از یکسان‌سازی انتهای سطر ساخته می‌شود و هش فایل دودویی با Path.read_bytes() حساب می‌شود. آزمون پیش‌فرض، جایگشت علامت جفتی با تصحیح Holm و بازه BCa است. بوت‌استرپ studentized و شمارش دقیق علامت برای $n \leq 40$ اختیاری‌اند تا اعداد کمپین منتشرشده جابه‌جا نشود.

۴- پروفایل زیست‌پزشکی

حوزه پزشکی از DomainProfile می‌آید. نام‌های موجود، alife، biomedical و hardware هستند [۱۵]. simd_declared و samd_declared عبارت IMDRF را روی بسته یادداشت می‌کنند و خود محصول را رده‌بندی نمی‌کنند. اگر مدل فیزیک‌محور اعلام نشده باشد، نسبت به راهنمای سال ۲۰۲۳ خارج از دامنه می‌ماند، حتی وقتی خانه‌های شواهد پر شده باشند. رشته‌هایی مانند asme_vv40_passed، fda_cleared، clinical_validated و iec_62304_certified در پیکربندی قبول نمی‌شوند. از یک جدول اعلامی مهر تأیید بیرون نمی‌آید.

جدول ۲: نگاشت واژگان تنظیم‌گری به برجسب‌های اعلامی

مفهوم استاندارد	میدان اعلامی	رفتار پورت
پرسش مورد علاقه (QOI)	question_of_interest	ثبت پرسش
زمینه کاربرد (COU)	context_of_use	ثبت زمینه کاربرد
تأثیر مدل / پیامد تصمیم	model_influence / decision_consequence	برجسب ریسک تصمیم
ریسک مدل	model_risk	برجسب ریسک مدل
دسته‌های شواهد FDA 2023	fda_2023_evidence	برجسب دسته شواهد
رده IEC 62304	iec_62304_class	برجسب رده نرم‌افزار
دسته IMDRF N12	imdrf_n12_category	برجسب دسته N12
SiMD در برابر SaMD	device_software_ki nd	برجسب SiMD/SaMD
اعتبار در برابر ریسک	نردبان ۵-۰ روی ادعا	درجه ادعا روی نردبان

جدول ۳ همان بسته‌ای است که در بخش ارزیابی به حسابرس

داده شده است. امتیازها برای نشان دادن قالب جدول اند و سطحی که برمی گردد صفر است.

جدول ۳: بسته اعلامی مدل تجهیز؛ خروجی حسابرس سطح *

میدان	مقدار نمونه	نوع
زمینه کاربرد	جدول مصنوعی؛ بدون ISO و ایمپلنت	اعلامی
تأثیر / پیامد	۲ / ۳؛ ریسک مدل ۳	اعلامی
device_software_ki nd	simd_declared	اعلامی
ردۀ IEC 62304	B	اعلامی
دستۀ IMDRF N12	II	اعلامی
شواهد FDA 2023	۱، ۳، ۸	اعلامی
physics_based	بله؛ سطح نردبان همچنان *	اجرایی

۵- ارزیابی

۵-۱- کمپین تأییدی HE01

HE01 طرحی از پیش ثبت شده برای سنجش سوگیری منشأ کپسول است. سی بذر جفتی، بازوی درمان را با چهار کنترل مقایسه می کند: محتوای تهی، کانال بسته، کانال روشن بدون سوگیری، و محتوای برخورد. پاسخ به شدت دوز جدا نگه داشته می شود تا با اثر اصلی مخلوط نشود. سنجه اصلی میانگین انرژی پایانی گیرنده است و این انرژی داخل شبیه سازی تعریف شده، نه یک کمیت زیستی. در مصنوع منتشر شده سقف ادعا intervention_supported است. آزمون پیش فرض، جایگشت علامت جفتی، تصحیح Holm و بازۀ BCa است.

فایل results_v7.json با پیشوند اثرانگشت 28f812c5 سه مقایسه جفتی دارد [۱۶]. نسبت به کانال روشن و بدون سوگیری منشأ، اختلاف ۱۶۴۹ واحد است. p خام جایگشت 10×499975 -⁵ و p پس از Holm برابر 10×10^{-4} است. بازۀ BCa نیز [۱۹۱۴، ۱۴۲۵] است. نسبت به کانال بسته و محتوای تهی، اختلاف ۳۰۶۷ واحد و بازۀ [۲۶۰۳، ۳۵۳۲] است. در مقایسه اول کانال سر جای خود می ماند و فقط سوگیری برداشته می شود. در مقایسه دوم هم محتوا عوض می شود و هم سوگیری. اگر همان سی اختلاف را با بوت استرپ studentized، که اختیاری است، دوباره حساب کنیم، بازه حدود ۱۴۰۵ تا ۱۹۳۰ می شود. این تفاوت از روش می آید و فایل ۷۷ دست نخورده است.

شکل ۲: تفاضل میانگین انرژی و بازۀ ۹۵٪ در ۳۰ بذر جفتی.

جدول ۴: خلاصه کمپین تأییدی HE01 از مصنوع ۷۷ (بازتقطیع نشده)

سنجه	مقدار منتشر شده
تعداد بذر جفتی	۳۰
سنجه اولیه	میانگین ATP پایانی گیرنده
source_bias_on در برابر source_bias_off	$\Delta = 1649$ BCa ؛ [۱۴۲۵، ۱۹۱۴]
source_bias_on در برابر capsules_off / content_null	$\Delta = 3067$ BCa ؛ [۲۶۰۳، ۳۵۳۲]
p جایگشت علامت (خام / (Holm)	10×499975 / 10^{-5} × ۱۰-۴
سقف ادعا در مصنوع	intervention_supported
بازپخش	در بسته شواهد ثبت می شود

۵-۲- حسابرس روی بسته اعلامی

جدول ۳ با زمینه کاربرد یک مدل تجهیز ساخته و به حسابرس داده شد. سؤال این بود که آیا جدول امتیاز اجازه می دهد اندازۀ بدترین حالت انتخاب شود. زمینه فقط همان جدول است و آزمون ISO 14879-1 و ایمپلنت در میان نیست. تأثیر مدل ۲ و پیامد تصمیم ۳ اعلام شده، بنابراین ریسک مدل ۳ ثبت می شود. امتیاز درمان ۰٫۱۲، ۰٫۱۱ و ۰٫۱۳ و امتیاز کنترل ۰٫۲۰، ۰٫۱۹ و ۰٫۲۱ است. برچسب های همراه عبارت اند از simd_declared، ردۀ B و IEC 62304، دستۀ II در IMDRF، دسته های شواهد ۱ و ۳ و ۸، و اعلام فیزیک محور بودن مدل. خروجی سطح صفر بود. برای سطح ۱ فقط مانیفست مصنوع کم است. HE01 چون بازپخش، مداخله، کنترل منفی، بازه و سی بذر دارد به سطح ۴ می رسد. برچسب رده و دسته شواهد این فاصله را عوض نمی کند.

۵-۳- نسبت این کار با V&V 40

ASME V&V 40 روش اعتبار یک مدل در زمینه کاربرد مشخص است. در این بستر، پرسش، زمینه، تأثیر و پیامد ثبت می شود و سپس ادعای همراه بسته درجه می گیرد. اگر آزمون نیمکت یا in vivo در دست باشد، بیرون از نرم افزار جمع می شود و فقط به شکل دستۀ راهنمای ۲۰۲۳ FDA اعلام می گردد. کودون تریس جای آن آزمون ها را نمی گیرد و حساب ادعا را نگه می دارد. نسخه از پیکربندی پروژه خوانده می شود و اعداد کمپین در این متن دوباره تولید نشده اند.

۶- محدودیت ها

موضوع این مطالعه درجه ادعای همراه مصنوع است. راهنمای FDA سال ۲۰۲۳ مدل یادگیری ماشین مستقل را در بر نمی گیرد. در HE01 مقایسه با کنترل محتوایی، مداخله ای مرکب است. گام بعدی، گذاشتن مدل فیزیک محور واقعی با مانیفست و زمینه کاربرد مشخص روی همین پورت است.

research in computational evolutionary biology,” *Artif. Life*, vol. 10, no. 2, pp. 191–229, 2004, doi: 10.1162/106454604773563612

[۱۲] M. Flageat, H. Janmohamed, B. Lim, and A. Cully, “Exploring the performance-reproducibility trade-off in quality-diversity,” *IEEE Trans. Evol. Comput.*, vol. 30, no. 1, pp. 286–295, Feb. 2026, doi: 10.1109/TEVC.2025.3548438

[۱۳] V. Grimm et al., “The ODD protocol for describing agent-based and other simulation models: A second update to improve clarity, replication, and structural realism,” *J. Artif. Soc. Soc. Simul.*, vol. 23, no. 2, art. 7, 2020, doi: 10.18564/jasss.4259

[۱۴] CodonTrace Genesis, “Ports, not a domain-specific engine,” [docs/ARCHITECTURE_PORTS.md](https://github.com/CodonTrace/Genesis/blob/main/docs/ARCHITECTURE_PORTS.md), 2026

[۱۵] CodonTrace Genesis, “Biomedical engineering interface,” [docs/BIOMEDICAL_ENGINEERING.md](https://github.com/CodonTrace/Genesis/blob/main/docs/BIOMEDICAL_ENGINEERING.md), 2026

[۱۶] Hard Experiment 01 confirmatory artifact, [docs/hard_experiment_01/results_v7.json](https://github.com/CodonTrace/Genesis/blob/main/docs/hard_experiment_01/results_v7.json), digest prefix 28f812c5

[۱۷] P. Pathmanathan, K. Aycock, A. Badal, et al., “Credibility assessment of in silico clinical trials for medical devices,” *PLoS Comput. Biol.*, vol. 20, no. 8, e1012289, 2024, doi: 10.1371/journal.pcbi.1012289

[۱۸] B. A. Craven, C. A. Basciano, P. Afshari, et al., “Computational modeling and simulation for medical devices: a summary of the 2024 FDA/MDIC Symposium,” *Prog. Biomed. Eng.*, vol. 8, no. 1, 013001, 2026, doi: 10.1088/2516-1091/ae1c05

۷- نتیجه‌گیری

کودون‌تریس جنسیس اجرا، مداخله و حسابرسی ادعا را روی یک نردبان جمع کرده و موتور را نسبت به حوزه بی‌طرف گذاشته است. پروفایل زیست‌پزشکی واژگان 40 ASME V&V، راهنمای FDA IEC 62304، ۲۰۲۳ و IMDRF را به همین نردبان می‌آورد. HE01 اختلاف انرژی را با بازه اطمینان و سی بذریافتی نشان داد. جدول اعلامی تجهیز، با ریسک مدل ۳ و برچسب‌های تنظیم‌گری، در سطح صفر ماند. برچسب استاندارد به‌تنهایی سطح ادعا را بالا نمی‌برد.

داده و کد: <https://github.com/Parvaz-Jamei/codontrace-genesis>
— DOI: 10.5281/zenodo.20337435

مراجع

[۱] U.S. Food and Drug Administration, “Assessing the Credibility of Computational Modeling and Simulation in Medical Device Submissions,” Guidance for Industry and FDA Staff, Nov. 2023

[۲] ASME, V&V 40-2018: Assessing Credibility of Computational Modeling through Verification and Validation: Application to Medical Devices. New York, NY, USA: ASME, 2018

[۳] NASA, NASA-STD-7009B: Standard for Models and Simulations. Washington, DC, USA: NASA, 5 Mar. 2024

[۴] Regulation (EU) 2024/1689 of the European Parliament and of the Council (Artificial Intelligence Act), Annex IV

[۵] M. Viceconti, F. Pappalardo, B. Rodriguez, M. Horner, J. Bischoff, and F. Musuamba Tshinanu, “In silico trials: Verification, validation and uncertainty quantification of predictive models used in the regulatory evaluation of biomedical products,” *Methods*, vol. 185, pp. 120–127, 2021, doi: 10.1016/j.ymeth.2020.01.011

[۶] F. Angermeir, M. Amougou, M. Kreitz, et al., “Reflections on the reproducibility of commercial LLM performance in empirical software engineering studies,” *Proc. IEEE/ACM 48th Int. Conf. Software Engineering (ICSE)*, 2026, doi: 10.1145/3744916.3773207

[۷] ASME, VVUQ 40.1-2026: An Example of Assessing Computational Model Credibility Using the ASME V&V 40 Risk-Based Framework: Tibial Tray Component Worst-Case Size Identification for Fatigue Testing. New York, NY, USA: ASME, 2026

[۸] IEC 62304:2006+AMD1:2015, Medical device software — Software life cycle processes. Geneva, Switzerland: IEC

[۹] IMDRF, Software as a Medical Device: Possible Framework for Risk Categorization and Corresponding Considerations, IMDRF/SaMD WG/N12 FINAL:2014

[۱۰] IMDRF, Characterization Considerations for Medical Device Software and Software-Specific Risk, IMDRF/SaMD WG/N81 FINAL:2025, Jan. 2025

[۱۱] C. Ofria and C. O. Wilke, “Avida: A software platform for